

**Учебно-методический материал по разделу
«Анализ временных рядов» курсового проекта
по дисциплине «Введение в проектную деятельность»**

1. Введение

Временной ряд – это хронологически упорядоченная последовательность наблюдений некоторой величины, которые сделаны через равные промежутки времени. Интеллектуальная обработка временного ряда учитывает хронологический порядок наблюдений и опирается на предположение о том, что значение ряда в текущий момент времени зависит от значений в предыдущие моменты.




Рис. 1. Пример временного ряда

Во многих практических задачах в каждый момент времени регистрируется не одно, а несколько значений. Например, метеостанция фиксирует температуру, давление, влажность, скорость и направление ветра. В этом случае данные представляют собой **многомерный временной ряд**. Многомерный временной ряд можно представить в виде матрицы, где строки соответствуют различным показателям (каналам, измерениям, признакам), а столбцы – моментам времени.




Рис. 2. Пример многомерного временного ряда

Интеллектуальная обработка многомерных рядов сложнее, чем одномерных, поскольку требуется учитывать не только временные зависимости внутри каждого канала, но и взаимосвязи между различными каналами.

Временные ряды являются одной из наиболее распространенных форм данных, встречающихся в самых разных сферах: от финансов и экономики до медицины, промышленности и экологии. Интеллектуальная обработка временных рядов позволяет обнаруживать скрытые закономерности в данных,

предвидеть развитие событий и своевременно реагировать на нештатные ситуации.


Одними из основных (базовых) задач интеллектуальной обработки временных рядов относят поиск аномалий, прогноз, классификацию и сегментацию, краткое описание которых дано ниже.

1. Задача обнаружения аномалий

Обнаружение аномалий во временном ряде заключается в нахождении одиночного наблюдения или последовательностей наблюдений, которые существенно отличаются от остальных данных и не соответствуют ожидаемому поведению ряда.

Различаю три типа аномалий:

- *точечные аномалии (выбросы)* – отдельные наблюдения, которые резко выделяются, выходят далеко за пределы стандартного диапазона или ожидаемого поведения.
- *контекстные аномалии* – наблюдения, нормальные сами по себе, но аномальные в данном контексте (например, высокая температура зимой).
- *коллективные аномалии* – последовательности наблюдений, которые совместно образуют аномальный паттерн.



а) точечная аномалий б) контекстная аномалия в) коллективная аномалия

Рис. 3. Типы аномалий во временных рядах

Применение: мониторинг промышленного оборудования, выявление мошеннических транзакций, обнаружение вторжений в компьютерные сети, медицинская диагностика.

2. Задача прогнозирования

Прогнозирование временных рядов заключается в предсказании будущих значений ряда на основе анализа его прошлых наблюдений и, возможно, внешних факторов.

Прогнозирование временных рядов различается по глубине (горизонту) заглядывания в будущее. Выделяют следующие виды прогнозирования по величине временного горизонта:

- *краткосрочное:* на один-два шага вперед;
- *среднесрочное:* на несколько шагов;
- *долгосрочное:* на много шагов вперед.



Рис. 4. Прогнозирование временного ряда

Применение: прогнозирование спроса, финансовое прогнозирование, прогнозирование загрузки серверов, метеорологические прогнозы, демографические прогнозы.

3. Задача классификации/сегментации

Классификация заключается в отнесении временного ряда целиком или его отдельного сегмента к одному из классов, смысл которых заранее известен. Сегментация заключается в разбиении длинного ряда на непересекающиеся участки (сегменты), каждый из которых имеет свою заранее не известную интерпретацию.




Рис. 5. Классификация временных рядов




Рис. 6. Сегментирование временного ряда

Применение: медицинская диагностика, распознавание активности, техническая диагностика, обработка сигналов.

2. Выполнение задания

Задание состоит из двух частей. Первая часть предполагает поиск подходящего набора данных временных рядов, который должен соответствовать одной из задач интеллектуального анализа данных (поиск аномалий, прогнозирование). Вторая часть заключается в разработке программы на языке Python, выполняющей первичный анализ выбранного набора данных и визуализацию полученных результатов. Перечень рекомендуемых наборов данных для анализа представлен в таблице ниже.

Студент также может самостоятельно подобрать наиболее интересующий его набор данных. В этом случае необходимо предварительно согласовать свой выбор с преподавателем. Предпочтительны референсные наборы данных, размещенные в авторитетных свободно доступных интернет-репозиториях (например, UCI Machine Learning Repository <https://archive.ics.uci.edu/>) или/и упомянутые в научных статьях, опубликованных в авторитетных рецензируемых журналах.

Необходимо создать репозиторий курсового проекта, в котором сохранять исходные тексты, набор данных, визуализацию и др. Исходные тексты должны быть документированы: содержать спецификации файлов и подпрограмм, а также комментарии, поясняющие ключевые этапы обработки данных.

Таблица 1. Перечень рекомендуемых наборов данных для анализа

№	Название	Предметная область	Задача	Ссылка
1	SKAB (Skoltech Anomaly Benchmark)	Промышленность	Поиск аномалий для выявления поломок и неисправностей промышленного оборудования	https://github.com/waico/SKAB
2	MIT-BIH Supraventricular Arrhythmia Database	Медицина	Поиск аномалий для мониторинга нарушений сердечного ритма (аритмии) у пациентов	https://physionet.org/content/svdb/1.0.0/
3	Annotated 12-lead ECG dataset			https://zenodo.org/records/3625027
4	NVIDIA Daily Stock Prices Dataset	Ритейл и экономика	Прогнозирование спроса, стоимости на товары в магазине	https://www.kaggle.com/datasets/ibrahimshahruck/nvidia-daily-stock-prices-20162026-dataset/data
5	Power Consumption of Tetouan City	Энергетика	Прогнозирование потребления электроэнергии городом	https://archive.ics.uci.edu/dataset/849/power+consumption+of+tetouan+city

6	Electricity Transformer Dataset		Прогнозирование температуры масла силового трансформатора	https://github.com/zhouhaoyi/ETDataset/tree/main
7	Air Quality Dataset	Экология	Прогнозирование концентрации угарного газа в воздухе	https://www.kaggle.com/datasets/fedesoriano/air-quality-data-set/data
8	Beijing PM2.5		Прогнозирование концентрации взвешенных частиц PM2.5 в воздухе	https://archive.ics.uci.edu/dataset/381/beijing+pm2+5+data

3. Этапы выполнения первичного анализа временных рядов

Этап 1. Загрузка и первичное знакомство с данными

Данный этап является отправной точкой любого анализа данных. Его цель – загрузить выбранный набор данных в среду разработки для Python и получить общее представление о его структуре. На этом этапе определяется размерность данных (количество каналов, длина временного ряда), типы данных в каждом канале временного ряда, наличие и формат временной метки. Это позволяет убедиться в корректности загрузки и выявить очевидные проблемы на самом раннем этапе.

Для *реализации* выполните следующие шаги:

1. Импортируйте необходимые библиотеки для загрузки данных. В зависимости от формата файла выберите соответствующую функцию.
2. После загрузки выведите первые строки данных для визуального ознакомления, получите общую информацию о данных и определите размерность данных.
3. При наличии столбца с датой/временем выполните преобразование в формат `datetime` и установите его в качестве индекса.

По результатам выполнения этапа сделайте следующие *выводы* и задокументируйте их в отчете:

- Корректность загрузки: удалось ли загрузить данные без ошибок?
- Соответствие описанию: совпадает ли фактическая структура данных с описанием из источника?
- Размерность: какова длина ряда, является ли ряд многомерным, сколько измерений (каналов) содержит ряд?
- Временная метка: присутствует ли в данных временная метка, в каком формате, требуется ли преобразование?
- Типы данных: каким типом данных представлен каждый канал?

Этап 2. Визуализация исходных данных

Визуализация позволяет получить первое наглядное представление о поведении временных рядов. Графический анализ помогает обнаружить общие закономерности (тренды, сезонность), выявить визуальные аномалии (резкие скачки, провалы), сравнить поведение различных каналов между собой. Этот этап формирует первичные гипотезы, которые будут проверяться количественными методами на последующих этапах. Способ визуализации и акценты при анализе зависят от того, для какой задачи предназначен выбранный набор данных.

Для *реализации* выполните следующие шаги:

1. Импортируйте необходимую библиотеку для визуализации данных (matplotlib.pyplot для построения статичных графиков или plotly для создания интерактивных визуализаций).
2. Для визуализации многомерных рядов создайте несколько подграфиков, располагая каналы друг под другом для удобства сравнения. Каждый канал многомерного ряда должен быть построен в виде линейного графика. Добавьте заголовки, подписи осей, легенду и сетку для улучшения читаемости.

Комментарий: При визуализации следует учитывать специфику выбранной задачи и наличие в наборе данных истинной разметки:

- *для наборов данных, связанных с задачей поиска аномалий:* если в данных присутствуют метки аномалий, необходимо выделить красным цветом аномальные участки на графиках. Такая визуализация позволяет наглядно оценить, насколько аномалии выделяются на фоне нормального поведения.
- *для наборов данных, связанных с задачей прогнозирования:* если в наборе предусмотрено разделение на обучающую и тестовую выборки, можно визуально выделить границу между ними, например, вертикальной линией. Это поможет оценить, насколько распределение данных сохраняется на тестовой выборке.

По результатам выполнения этапа сделайте следующие **выводы**, учитывая специфику выбранного набора данных, и задокументируйте их в отчете:

Для поиска аномалий:

1. Совпадают ли размеченные аномалии с визуально наблюдаемыми аномалиями?
2. Какие типы аномалий (точечные, контекстные, коллективные) присутствуют?

Для прогнозирования:

1. Просматривается ли в данных общий тренд (рост, падение, стабильность)?
2. Наблюдаются ли повторяющиеся паттерны (суточная, недельная, годовая сезонность)?
3. Насколько поведение ряда регулярно и предсказуемо?

Общие выводы для всех задач:

1. Есть ли на графиках разрывы, указывающие на наличие пропущенных значений в данных?
2. Ведут ли себя разные каналы похоже или наблюдаются существенные различия?

Этап 3. Статистический анализ

Статистический анализ дополняет визуальное восприятие точными количественными характеристиками. На этом этапе рассчитываются описательные статистики, которые позволяют понять, где сосредоточены основные значения данных (среднее, медиана), как сильно они разбросаны (стандартное отклонение) и в каких пределах изменяются (минимум, максимум, квартили). Определяется частота дискретизации временного ряда. Полученная информация необходима для обнаружения потенциальных выбросов и для последующего выбора методов масштабирования данных.

Для *реализации* выполните следующие шаги:

1. Найдите статистические характеристики (count, mean, std, min, Q1, Q2, Q3, max) для каждого канала многомерного временного ряда и представьте их в табличной форме.
2. Определите частоту дискретизации.

По результатам выполнения этапа сделайте следующие *выводы* и задокументируйте их в отчете:

1. Есть ли значения за допустимыми пределами?
2. Симметрично ли распределение (сравните среднее и медиану)? Сильная асимметрия укажет на необходимость нелинейных преобразований в будущем.
3. Какова дискретность ряда? Равномерны ли интервалы? Во всех каналах одинаковая дискретность?
4. Каков разброс значений по каналам? (по стандартному отклонению) Сильно ли различается разброс между каналами? Это укажет на необходимость масштабирования данных при использовании моделей, чувствительных к масштабу признаков.
5. Есть ли каналы со стандартным отклонением, близким к нулю? Такие каналы могут быть исключены из анализа как неинформативные.

Этап 4. Анализ пропусков и выбросов

Реальные данные, как правило, содержат пропуски и выбросы, которые могут существенно исказить результаты последующего анализа. Пропуски возникают из-за сбоев в работе измерительного оборудования или при передаче данных. Выбросы могут быть как следствием ошибок измерения, так и отражением реальных аномальных событий. Данный этап направлен на выявление и количественную оценку этих проблем для принятия в дальнейшем обоснованных решений об их обработке.

Для *реализации* выполните следующие шаги:

1. Вычислите долю пропущенных значений (%) в каждом измерении многомерного временного ряда.
2. Вычислите количество потенциальных выбросов по правилу трех сигм. Для визуального выявления выбросов постройте диаграмма размаха для каждого канала.

По результатам выполнения этапа сделайте следующие **выводы** и задокументируйте их в отчете:

1. Какие каналы содержат пропуски и/или выбросы?
2. Носят ли пропуски систематический характер (возникают в определенное время)?
3. На основе выявленных проблем сформулируйте предварительные рекомендации по обработке данных (удаление, восстановление) для следующего этапа работы.

Этап 5. Анализ диапазонов значений

Различные признаки могут измеряться в разных единицах и иметь существенно различающиеся масштабы. Например, один канал может изменяться в пределах единиц, а другой – в пределах тысяч. Многие алгоритмы машинного обучения чувствительны к масштабу признаков и будут неявно придавать больший вес каналам с большими числовыми значениями, что может исказить результаты. Данный этап направлен на выявление таких различий для обоснованного принятия решения о необходимости нормализации или стандартизации данных.

Для **реализации** выполните следующие шаги:

1. Для визуального сравнения диапазонов постройте общую диаграмму размаха для всех каналов на одном графике.

По результатам выполнения этапа сделайте следующие **выводы** и задокументируйте их в отчете:

1. Как различаются диапазоны значений по каналам? Есть ли каналы, масштаб которых существенно отличается от остальных?
2. Требуется ли нормализация/стандартизация? Что наиболее подходит под решаемую задачу и особенности данных?

Этап 6. Корреляционный анализ

В многомерных временных рядах каналы редко бывают независимы. Корреляционный анализ позволяет измерить силу и направление линейных связей между различными каналами, что важно для понимания структуры данных, выявления дублирующих признаков и отбора наиболее информативных каналов для последующего моделирования.

Для **реализации** выполните следующие шаги:

1. Вычислите матрицу парных коэффициентов корреляции Пирсона между всеми каналами многомерного временного ряда.
2. Визуализируйте найденную матрицу в виде тепловой карты.

По результатам выполнения этапа сделайте следующие **выводы** и задокументируйте их в отчете:

1. Какие пары каналов имеют наиболее сильную положительную корреляцию? Может ли это указывать на дублирование информации?
2. Есть ли каналы с сильной отрицательной корреляцией? О чем это может говорить?
3. Есть ли каналы, практически не коррелирующие с остальными? Возможно, они несут уникальную информацию, независимую от других измерений.

Для задачи прогнозирования:

4. Какие каналы наиболее сильно коррелируют с целевой переменной? Есть ли мультиколлинеарность (сильная корреляция между признаками), которая может потребовать отбора признаков?

Этап 7. Поиск и анализ шумов

Шум – это случайные колебания, которые присутствуют в любых реальных данных и мешают увидеть истинные закономерности. Данный этап посвящен выделению шумовой компоненты из временного ряда, ее количественной оценке и определению характера шума. Исследование шума необходимо для того, чтобы понять, насколько сильно случайные колебания искажают полезный сигнал, и принять обоснованное решение о необходимости фильтрации данных. Сильный шум может сделать прогнозы неточными, а модели детекции аномалий неспособными отличить реальные события от случайных флуктуаций. Таким образом, цель этапа – оценить качество данных и определить, требуется ли их очистка перед решением практических задач.

Для *реализации* выполните следующие шаги:

1. Выберите один ключевой канал и выполните декомпозицию ряда на три составляющие (тренд, сезонная компонента, остатки (шум)) с помощью функции `seasonal_decompose()` из библиотеки `statsmodels.tsa.seasonal`. Для этого необходимо:
 - задать период сезонности (например, 24 для почасовых данных с суточной сезонностью, 168 для недельной);
 - выбрать модель декомпозиции: параметр `model` установите в `'additive'` (аддитивная модель) или `'multiplicative'` (мультипликативная модель) в зависимости от характера данных.
2. Визуализируйте результаты декомпозиции, построив четыре графика, расположенных вертикально друг под другом: исходный ряд, ряд с выделенным трендом, ряд с сезонной компонентой, ряд с остатками (шумом). Это позволит наглядно оценить вклад каждой компоненты и увидеть структуру шума.
3. Выделите сигнал, объединив тренд и сезонную компоненту в зависимости от выбранной модели декомпозиции:
 - для аддитивной модели (`model='additive'`):

сигнал = тренд + сезонность;

- для мультипликативной модели (model='multiplicative'):

$$\text{сигнал} = \text{тренд} \times \text{сезонность}.$$

Сигнал представляет собой очищенную от шума часть данных, содержащую все регулярные закономерности ряда.

4. Рассчитайте отношение сигнал/шум (SNR, signal-to-noise ratio) по формуле:

$$\text{SNR} = 10 * \log_{10} \left(\frac{\sigma_{\text{сигнал}}^2}{\sigma_{\text{шум}}^2} \right),$$

где $\sigma_{\text{сигнал}}^2$ – дисперсия сигнала, $\sigma_{\text{шум}}^2$ – дисперсия остатков.

SNR показывает, во сколько раз мощность полезного сигнала превышает мощность шума. Чем выше SNR, тем меньше шум мешает найти истинные закономерности в данных.

5. Для визуальной оценки характера шума постройте гистограмму распределения остатков.

По результатам выполнения этапа сделайте следующие **выводы** и задокументируйте их в отчете:

1. Что показывает тренд? Укажите направление тренда (рост, падение, стабильность) и его интенсивность (сильный, умеренный, слабый).
2. Какая сезонность обнаружена? Определите период (суточная, недельная, годовая) и амплитуду сезонных колебаний (высокая, средняя, низкая).
3. Каково значение SNR? Дайте качественную интерпретацию SNR, основываясь на информации из таблицы ниже.

Таблица 2. Интерпретация значений SNR

SNR	Качественная оценка	Что это означает на практике
> 20 дБ	Отлично	Шум практически незаметен, данные очень чистые. Модели будут хорошо видеть закономерности.
10–20 дБ	Хорошо	Шум присутствует, но сигнал доминирует. Модели будут работать стабильно.
0–10 дБ	Удовлетворительно	Сигнал и шум сравнимы по мощности. Данные пригодны для анализа, но требуется фильтрация для повышения точности моделей.
< 0 дБ	Плохо	Шум сильнее полезного сигнала. Данные практически непригодны для анализа без серьезной фильтрации.

4. Какова форма распределения остатков? (нормальная, с тяжелыми хвостами, асимметричная, мультимодальная) Объясните, что форма распределения говорит о качестве данных, опираясь на таблицу ниже.

Таблица 3. Интерпретация формы распределения шума (остатков)

Форма распределения	Что это означает	Какие выводы можно сделать
Нормальное (колоколообразное), симметричное	Шум случаен, некоррелирован, близок к классическому «белому шуму». Модель декомпозиции адекватно выделила все закономерности, в остатках не осталось полезной информации.	Данные хорошо очищены от шума. Фильтрация не требуется. Можно работать с исходными данными.
Тяжелые хвосты (много значений далеко от центра)	В данных присутствуют редкие, но сильные выбросы. Шум не подчиняется нормальному распределению, есть экстремальные значения.	Для фильтрации лучше использовать медианный фильтр, а не скользящее среднее. При поиске аномалий нужно быть осторожным – часть «хвоста» могут быть реальными событиями.
Асимметрия (скошено влево или вправо)	Шум несимметричен, возможно, есть систематическая ошибка измерений или нелинейность процесса.	Может потребоваться преобразование данных (логарифмирование, степенное преобразование) перед анализом.
Мультимодальность (несколько пиков)	В шуме осталась структура. Возможно, декомпозиция не полностью уловила сигнал, и часть закономерностей осталась в остатках.	Вернуться к декомпозиции, возможно, выбран неправильный период сезонности или не учтены другие регулярные компоненты.
Равномерное распределение	Шум имеет искусственное происхождение, например, округление измерений или квантование.	Это не критично, но может ограничивать точность анализа.
Дискретное распределение	Шум принимает только определенные значения. Возможно, данные были округлены или получены с низкоточного датчика.	Стоит проверить исходные данные – возможно, это особенность измерения.

5. Требуется ли фильтрация данных? Если да, то какие методы предварительно рекомендуются (скользящее среднее, медианный фильтр, другие)?